

Proyecto

Integrantes:

Victor Pointud

Juan Salima

Bernardo Lander

Para explicar las etapas del Machine Learning dentro del contexto específico de un proyecto o iniciativa como podría ser con IBM Cloud for Pak, necesitamos desglosar las fases típicas de un proyecto de Machine Learning y cómo se aplican.

Fuentes de Datos

En cualquier proyecto de Machine Learning, todo comienza con las fuentes de datos. Estas pueden ser internas (dentro de la organización) o externas. Las fuentes de datos pueden incluir bases de datos de clientes, logs de sistemas, información recopilada de sensores, datos de redes sociales, y más. La clave está en identificar qué datos son relevantes para el problema que se está intentando resolver.

Puedes demostrar esta etapa mostrando cómo se identifican y acceden a las fuentes de datos. Por ejemplo, conectando a una base de datos SQL para extraer datos de clientes.

ETL (Extract, Transform, Load)

No todos los proyectos de Machine Learning requieren una fase ETL, pero muchos lo hacen. Esta etapa implica extraer datos de las fuentes originales, transformarlos (limpieza, normalización, manejo de valores faltantes, etc.) para que sean aptos para el análisis, y finalmente cargarlos en un sistema donde puedan ser accedidos por herramientas de análisis y modelado.

Mostrar un script o un proceso automatizado que toma datos crudos, los limpia (por ejemplo, elimina registros duplicados, maneja valores faltantes), y los carga en una nueva base de datos diseñada específicamente para análisis.

Diseño de la Base de Datos

Dependiendo del proyecto, el diseño de la base de datos puede variar significativamente. Para proyectos de Machine Learning, es común diseñar esquemas que faciliten el análisis rápido, la experimentación con modelos, y el acceso a datos históricos para entrenamiento.

Crear un diagrama de entidad-relación (ER) o un modelo de datos que muestre cómo se organizarán los datos para facilitar el análisis y el Machine Learning.

Funcionamiento

Esta etapa se refiere a la implementación de modelos de Machine Learning, desde la selección de modelos, entrenamiento, validación, y finalmente, despliegue. Es crucial seleccionar el modelo adecuado según el problema y los datos disponibles.

Un notebook de Jupyter mostrando el proceso de selección de modelo, entrenamiento, validación (incluyendo la división de los datos en sets de entrenamiento y test), y una demostración de cómo el modelo hace predicciones sobre datos nuevos.

Indicadores

Los indicadores (o métricas) son cruciales para evaluar el rendimiento de los modelos de Machine Learning. Estos pueden incluir precisión, recall, F1 score, AUC-ROC, entre otros, dependiendo del tipo de problema (clasificación, regresión, etc.).

Presentar un dashboard o reporte que muestre cómo se evalúan los modelos utilizando estas métricas. Esto puede incluir comparaciones de diferentes modelos o la evolución del rendimiento de un modelo a lo largo del tiempo.

Para obtener detalles específicos sobre cómo IBM Club for Pak implementa estas etapas, sería ideal consultar directamente con fuentes o publicaciones específicas del club, ya que los detalles pueden variar significativamente de un proyecto a otro.

Regresión lineal

Es un método estadístico que se utiliza para modelar la relación entre una variable dependiente y una o más variables independientes, asumiendo que la relación es lineal. Sirve para predecir el valor de una variable basándose en el valor de otras variables. Por ejemplo, podría usarse para predecir las ventas futuras basándose en la publicidad gastada, o para estimar el precio de una casa según su tamaño y ubicación. Es ampliamente utilizada en ciencia de datos, economía, y en investigación para identificar factores que influyen en un fenómeno y para hacer pronósticos.

Combinar una base de datos NoSQL con un modelo de IA de regresión lineal

- 1. Entendimiento de los Datos:** Familiarizarse con la estructura de la base de datos NoSQL y los datos disponibles. Entender cómo se relacionan los datos con el problema que se quiere resolver.
- 2. Preparación de los Datos:** Extraer los datos necesarios de la base de datos NoSQL. Esto puede requerir consultas específicas para estructurar los datos de manera adecuada para el análisis.
- 3. Limpieza y Preprocesamiento:** Transformar los datos para el modelo de regresión lineal, lo cual incluye manejar valores faltantes, normalizar o escalar datos, y posiblemente codificar variables categóricas.
- 4. Selección de Variables:** Identificar cuáles variables independientes (características) tienen el potencial de predecir la variable dependiente. Esto puede involucrar análisis exploratorios y selección de características.
- 5. Integración y Automatización:** Desarrollar un proceso automatizado para extraer los datos de la base NoSQL, pre-procesarlos y alimentarlos al modelo de IA. Esto puede requerir scripting y uso de APIs.
- 6. Desarrollo del Modelo de IA:** Utilizar los datos preprocesados para entrenar un modelo de regresión lineal. Ajustar el modelo para mejorar la precisión, incluyendo la selección del algoritmo adecuado y la afinación de hiper parámetros.
- 7. Evaluación del Modelo:** Probar el modelo con un conjunto de datos de prueba para evaluar su rendimiento, utilizando métricas como el R cuadrado, el error cuadrático medio, etc.
- 8. Despliegue y Operacionalización:** Integrar el modelo entrenado en el flujo de trabajo de la aplicación o el proceso de negocio, asegurando que pueda acceder y procesar datos en tiempo real o según sea necesario.
- 9. Monitoreo y Mantenimiento:** Establecer un sistema para monitorear el rendimiento del modelo con el tiempo, y actualizar el modelo y los datos según sea necesario para mantener o mejorar su precisión.

- **Objetivo principal:**

a) Obtención y Selección de Datos:

Seleccionar un conjunto de datos de Kaggle que sea relevante y tenga el potencial de aportar insights significativos para el problema en cuestión.

b) Limpieza y Preparación de Datos:

Realizar una limpieza exhaustiva de datos para eliminar o corregir datos faltantes, duplicados o irrelevantes.

Aplicar técnicas de transformación y normalización de datos para mejorar la calidad y la homogeneidad del conjunto de datos.

c) Entrenamiento y Optimización de Modelos de IA:

Entrenar varios modelos de IA utilizando diferentes algoritmos para comparar su efectividad.

Optimizar el modelo seleccionado mediante ajustes de hiperparámetros para mejorar su precisión y rendimiento.

d) Evaluación y Validación del Modelo:

Utilizar técnicas de validación cruzada para evaluar la precisión y la generalización del modelo.

Analizar la importancia de las características para entender cómo el modelo hace sus predicciones.

- **Que se quiere estimar y la relevancia referente a patrones anteriores**

Predecir la cantidad de productos vendidos en una fecha como por ciudad para los próximos meses, basándose en su comportamiento de compra histórico, preferencias de producto, y dinámicas estacionales observadas en el período de enero de 2017 a agosto de 2018.

a) Relevancia del Objetivo:

- **Optimización de Inventario:** Asegurar que los productos más demandados estén disponibles en las cantidades correctas.

- **Personalización de Marketing:** Dirigir esfuerzos de marketing para fomentar la repetición de compras, utilizando la personalización basada en el comportamiento pasado del cliente.
- **Mejora de la Experiencia del Cliente:** Entender mejor las necesidades y deseos de los clientes para mejorar la satisfacción y la lealtad.

b) Uso de Patrones Anteriores:

- **Tendencias de Compra:** Utilizar patrones de compra anteriores para identificar productos populares, tendencias estacionales, y eventos de ventas que influyen en el comportamiento del cliente.
- **Segmentación de Clientes:** Clasificar a los clientes según su valor de compra histórico, frecuencia, y categorías de productos comprados para predecir futuras compras.
- **Análisis de Retención:** Evaluar la probabilidad de churn de clientes basándose en su actividad de compra y engagement pasado.
- **Ejemplos de porqué sería útil y que es lo novedoso**

Se tienen varios ejemplos útiles a tomar en cuenta, ellos pueden ser:

- a) **Optimización del Inventario:** es fundamental para evitar tanto el exceso de stock como la falta de inventario, modificando las órdenes de compra con base en las predicciones de demanda futura derivadas del historial de compras de los clientes. Esto lleva a una reducción significativa en los costos asociados al exceso de stock y mejora la satisfacción del cliente al reducir los casos de productos agotados.
- b) **Estrategias de Marketing Personalizado:** son útiles para desarrollar campañas de marketing dirigido que sean más relevantes para los segmentos de clientes, basadas en sus patrones de compra pasados y futuras predicciones de compra. Las campañas de marketing predictivo pueden aumentar la tasa de respuesta y el retorno de inversión de marketing al dirigirse a los clientes con ofertas que tienen alta probabilidad de interesarles.

- c) La Mejora de la Experiencia del Cliente: se logra anticipando las necesidades y deseos de los clientes, ofreciendo recomendaciones de productos personalizadas y oportunas, lo que mejora la experiencia de compra, aumentando la lealtad y la satisfacción del cliente.

Estos serían algunos ejemplos de su uso que lo convierten en algo espectacular y novedoso ya que antes no se contaba con IA capaces de realizar dicha tarea con tasas de acierto elevadas.

- **De donde viene la información que se trabaja**

La información pertinente proviene de la página kaggle.com, específicamente del siguiente link: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce?select=olist_products_dataset.csv

El cuál posee un csv con un conjunto de archivos, datos, imágenes, mapas, entre otros correspondientes a las ventas de un ecommerce brasilero.

- **Tecnologías usadas y por que**

Se hizo uso de la página web Kaggle para extraer el csv con los datos para su análisis y uso de entrenamiento para la IA, luego se usó Spark con Databricks para la limpieza de los datos y acomodar lo necesario para que sirva su conexión en ibm, ya en ibm escogimos IBM Cloud pak for data dado que posee una IA capaz de hacer machine learning dependiendo de la información que se le suministre y ella misma aprende con el tiempo y dado los datos mejorando poco a poco su habilidad de dar una predicción lo más cercano al 100% de efectividad.

- **Indagar en la arquitectura de las tecnologías y como se integran**

Apache Spark

Es una plataforma de código abierto para el procesamiento de datos a gran escala, que ofrece capacidades de análisis en clusters de computadoras. Se destaca por su rapidez y su capacidad para manejar tareas de procesamiento por lotes, procesamiento en tiempo real, análisis interactivo, machine learning y procesamiento de grafos. Spark es ampliamente utilizado para analizar grandes conjuntos de datos debido a su eficiencia y su facilidad de uso, haciendo posible realizar cálculos complejos de manera rápida y distribuida. Se hizo uso de ella en este proyecto dado su versatilidad con respecto al manejo de csv de gran tamaño y búsqueda dentro de los mismos para la conexión a IBM.

IBM Watson Studio

Es una plataforma de ciencia de datos y aprendizaje automático que permite a los usuarios preparar datos, crear, entrenar y desplegar modelos de inteligencia artificial (IA) en un entorno colaborativo. Sirve para facilitar el análisis de datos, la creación de modelos predictivos y la implementación de soluciones de IA, apoyando a empresas y desarrolladores en la toma de decisiones basadas en datos y en la automatización de procesos. Esta pagina es increíble para nuestro caso dado que como queda expresado su modelo de IA es compatible perfectamente con el proyecto.

IBM Cloud Pak

Es una colección de soluciones de software empresarial de IBM que proporciona a las empresas herramientas para desplegar aplicaciones y datos en entornos de nube híbrida y multicloud. Sirve para automatizar procesos de TI, integrar seguridad en toda la infraestructura de TI, y facilitar el desarrollo de aplicaciones con tecnologías como IA y análisis de datos. Los Cloud Paks ofrecen capacidades en áreas como aplicaciones de negocio, automatización, integración de datos, seguridad, y observabilidad, permitiendo a las organizaciones modernizar sus operaciones y acelerar la transformación digital. Esto es un apartado de IBM Watson y se lleva con los requerimientos de nuestro proyecto a niveles de proyecciones, estadísticas, manejo de datos, aprendizaje automático sin falla perfectamente..

- **Modelo de datos y métodos de diseño de datos justificados (explicar como se usó databricks y como se paso a ibm)**


En el Spark Databricks lo primero fue la limpieza de los datos de kaggle, manipulandolo para obtener la tabla final que te muestra (Fecha de la compra, categoría del producto adquirido, y el lugar) haciendo unos módulos, que cada uno consta de un paso a seguir dando un total de 8.

En el 1er módulo Se hizo la unión de categoría de producto con su traducción y su ID, en el 2do modulo union de Nombre de producto con su ID de Orden, en el 3ero se unió de Nombre de producto con fecha de compra y ID de usuario, en el 4to se unió de Nombre de producto y fecha de compra con Ciudad de cliente, en el 5to se hizo Prueba#1 para AutoAI, en el 6to se hizo Prueba#2 para AutoAI, en el 6to se formateo de tabla para trabajo con AutoAI, El Count over 50 y por último se realizó una API.

Ya con todo lo anterior se suministra esa información a la IA creada en IBM Cloud Pak for Data dado Machine Learning y ella misma estudia, memoriza, analiza, entiende y da respuesta como predicción al valor que nosotros le digamos.


- **Pequeña demostración**

CSV sacado de Kaggle:



The screenshot shows the Kaggle dataset page for 'Brazilian E-Commerce Public Dataset by Olist'. The page includes a sidebar with navigation links (Create, Home, Competitions, Datasets, Models, Code, Discussions, Learn, More) and a main content area. The dataset is described as '100,000 Orders with product, customer and reviews info'. It includes sections for 'About Dataset', 'Join it With the Marketing Funnel by Olist', and 'Context'. The 'About Dataset' section provides details about the dataset's origin (Olist Store) and features (order status, price, payment, freight performance, product attributes, reviews, geolocation). The 'Join it With the Marketing Funnel by Olist' section mentions a related dataset and provides instructions on joining. The 'Context' section is currently empty. The right sidebar shows 'Usability' (10.00), 'License' (CC BY-NC-SA 4.0), 'Expected update frequency' (Never), and 'Tags' (Business, Data Visualization, Exploratory Data Analysis, NLP, Multiclass Classification).


Corrección de datos y uso de API en Spark Databricks



```

1 %python
2 import requests
3
4 # NOTE: you must manually set API_KEY below using information retrieved from your IBM Cloud account (https://dataplatform.cloud.ibm.com/docs/content/wsj/analyze-data/ml-authentication.html)
5 API_KEY = "SF7eoSLbSJS5ATgrW0J2HhdtiJ_3RBHtk8fz0cjEA0pr"
6 token_response = requests.post('https://iam.cloud.ibm.com/identity/token', data={"apikey":
7   API_KEY, "grant_type": 'urn:ibm:params:oauth:grant-type:apikey'}, timeout=150)
8 mltoken = token_response.json()["access_token"]
9
10 header = {'Content-Type': 'application/json', 'Authorization': 'Bearer ' + mltoken}
11
12 # NOTE: manually define and pass the array(s) of values to be scored in the next line
13 payload_scoring = {
14   "input_data": [
15     {
16       "fields": [
17         "customer_city",
18         "order_date"
19       ],
20       "values": [
21         ["sao paulo", "2018-09-30"],
22         ["rio de janeiro", "2018-11-24"],
23         ["sertaozinho", "2019-01-03"],
24         ["rio de janeiro", "2019-05-05"]
25       ]
26     }
27   ]
28 }
29
30 response_scoring = requests.post('https://private.us-south.ml.cloud.ibm.com/ml/v4/deployments/pepe5/predictions?version=2021-05-01', json=payload_scoring,
31   headers={"Authorization": "Bearer " + mltoken}, timeout=150)
32 print("Scoring response")
33 print(response_scoring.json())
  
```

Uso de los datos del csv, creación de los experimentos y modelos de IA junto al formato de predicción en IBM Cloud Pak for Data



Projects / ProyectoFinalBDD2

Overview Assets Jobs Manage

Find assets Import assets New asset +

9 assets

All assets

Asset types

- > Data (3)
- > Experiments (3)
- > Models (3)

Name	Last modified
export (2).csv CSV	2 hours ago Modified by you
spark_export_70 CSV	2 hours ago Modified by you
spark_export_limit200 CSV	2 hours ago Modified by you

Data in this project

Drop data files here or browse for files to upload

Projects / ProyectoFinalBDD2

Overview **Assets** Jobs Manage

Find assets Import assets New asset +

9 assets

All assets

Asset types

- Data 3
- Experiments 3**
- Models 3

Experiments

Name	Status	Model type	Last modified
CatxDateCityAI AutoAI experiment	Completed	Multiclass classification	2 hours ago Modified by you
CatxDateCity AutoAI experiment	Completed	Multiclass classification	2 hours ago Modified by you
CatxDate AutoAI experiment	Completed	Multiclass classification	2 hours ago Modified by you

Data in this project

Drop data files here or browse for files to upload

Projects / ProyectoFinalBDD2

Overview **Assets** Jobs Manage

Find assets Import assets New asset +

9 assets

All assets

Asset types


- Data 3
- Experiments 3
- Models 3**

Models

Name	Type	Software specification	Last modified
CatxDateCityAI - P8 Snap Random Forest... Model	wml-hybrid_0.1	hybrid_0.1	2 hours ago Modified by Service
CatxDate - P4 Random Forest Classifier - ... Model	wml-hybrid_0.1	hybrid_0.1	2 hours ago Modified by Service
CatxDateCity - P2 Snap Random Forest CL... Model	wml-hybrid_0.1	hybrid_0.1	2 hours ago Modified by Service

Data in this project

Drop data files here or browse for files to upload



- Reflexiones o conclusiones sobre los modelos

Projects / ProyectoFinalBDD2 / CatxDateCityAI - P8 Snap Random

- Governance
- Model
- Evaluation
 - Develop
 - ProyectoFinalBDD2
 - Training evaluation
- Attachments
 - Other attachments

Source type
CSV

Training evaluation

Metric	Training data	Holdout data
Accuracy	0.77642095	0.7761194
F1 macro	0.14569011	0.14565827
F1 micro	0.77642095	0.7761194
F1 weighted	0.67870116	0.67828923
Log loss	-0.8332544	-0.84371084
Precision macro	0.12940349	0.12935324
Precision micro	0.77642095	0.7761194
Precision weighted	0.6028295	0.6023613
Recall macro	0.16666667	0.16666667
Recall micro	0.77642095	0.7761194
Recall weighted	0.77642095	0.7761194

CatxDateCityAI - P8 Snap Random Forest Classifier - Model

Last modified at Apr 3, 2024 at 7:27 PM

Description
No description provided.

Created
Apr 3, 2024 at 5:35 PM

Type
wmt-hybrid_0.1

Model ID
cc31842b-0b4e-4325-8e73-7fe...

Software specification
[hybrid_0.1](#)

Hybrid pipeline software specifications
[autoai-kb_rt23.1-py3.10](#)

Tags
Add tags to make assets easier to find.

Queda en evidencia que el acierto es del 0,7746 que es igual a 77,46% de efectividad en las respuestas, esta fue la mejor a poder obtener, dado que entrenarlo para ser más exacto es muy complicado y consume mucho tiempo de ingresar datos, espera de su aprendizaje entre otros.