

Taller Spark

Integrantes:

Victor Pointud

Juan Salima

Bernardo Lander

Parte I

1. Crear una cuenta Community Edition en Databrick <https://databricks.com/>
2. 2. Crear un clúster llamado Cluster SparkSQL con la última versión disponible para LMS.
3. Importar en el workspace los cuadernos (notebooks) desde la siguiente url <https://files.training.databricks.com/courses/ucdavis/Lessons.dbc>
4. Abrir y ejecutar el notebook 1.4-SQL-Notebook que está en el módulo 1 del curso, y explicar qué hace (2 ptos).

Al abrir el notebook 1.4-SQL-Notebook del módulo 1 se ven las lessons que se van a estudiar que son:

- Crear una base de datos y tabla.
 - Calcular estadísticas agregadas contra un conjunto de datos.
 - Crear visualizaciones.
5. Hacer capturas de pantalla.



The screenshot shows the Databricks SQL Notebook interface. The top bar includes the Databricks logo, the notebook name "1.4-SQL-Notebook", and a star icon. Below the top bar, there are tabs for "File", "Edit", "View", "Run", and "Help". The notebook content is displayed in a scrollable area. The first cell (Cell 1) contains the Databricks Academy logo. The second cell (Cell 2) is a markdown cell titled "1.4 SQL in Notebooks" and contains a list of topics to be covered in the lesson: "Create a database and table", "Compute aggregate statistics against a dataset", and "Create visualizations". The third cell (Cell 3) is a markdown cell titled "Mounting Data" and contains text explaining that a "mount" is a pointer to a remote storage location (typically AWS or Azure) and that the notebook will run a "Classroom Setup" script to mount the data. The fourth cell (Cell 4) is a code cell containing the command `%run ../Includes/Classroom-Setup` and a status message: "Waiting for compute to start: Starting Spark".

The screenshot shows the Databricks SQL Notebook interface, continuing from the previous one. The top bar is the same. The notebook content is displayed in a scrollable area. The fifth cell (Cell 5) is a code cell containing the command `%run ../Includes/Classroom-Setup` and a status message: "Running command...". The sixth cell (Cell 6) is a markdown cell titled "Create a Database and Table". The seventh cell (Cell 7) is a markdown cell titled "SF Fire Department Calls for Service" and contains text explaining that the notebook will look at the "SF Fire Department Calls for Service" dataset, which includes all fire units responses to calls. The eighth cell (Cell 8) is a code cell containing the command `%fs head /mnt/davis/fire-calls/fire-calls-truncated-comma.csv`.

1.4-SQL-Notebook SQL ☆

File Edit View Run Help Last edit was 10 minutes ago New cell UI: OFF

Run all My Cluster Share Publish

1 %run ../Includes/Classroom-Setup

Command took 3.22 minutes — by victorpointud1112@gmail.com at 16/03/2024, 17:51:05 on My Cluster

Cmd 5

Create a Database and Table

Cmd 6

SF Fire Department Calls for Service

Let's take a look at the [SF Fire Department Calls for Service](#) dataset. This dataset includes all fire units responses to calls.

Cmd 7

1 %fs head /mnt/davis/fire-calls/fire-calls-truncated-comma.csv

[Truncated to first 65536 bytes]
Call Number,Unit ID,Incident Number,Call Type,Call Date,Watch Date,Received DtTm,Entry DtTm,Dispatch DtTm,Response DtTm,On Scene DtTm,Transport DtTm,Hospital DtTm,Call Final Disposition,Available DtTm,Address,City,Zipcode of Incident,Battalion,Station Area,Box,Original Priority,Priority,Final Priority,ALS Unit,Call Type Group,Number of Alarms,Unit Type,Unit sequence in call dispatch,Fire Prevention District,Supervisor District,Neighborhoods - Analysis Boundaries,Location,RowID
001030118,E08,00030625,Medical Incident,04/12/2000,04/12/2000,09:27:45 PM,04/12/2000 09:28:58 PM,04/12/2000 09:29:21 PM,04/12/2000 09:31:26 PM,04/12/2000 09:32:34 PM,,,,,Other,04/12/2000 09:45:28 PM,4TH ST/CHANNEL ST,SF,,,,,B03,08,2226,3,3,3,false,,,,,1,ENGINE,1,3,6,None,"(37.7750268633971, -122.392346204303)",001030118-E08
001030122,M18,00030630,Medical Incident,04/12/2000,04/12/2000,09:31:55 PM,04/12/2000 09:33:48 PM,04/12/2000 09:34:10 PM,04/12/2000 09:35:59 PM,04/12/2000 09:45:22 PM,,,,,Other,04/12/2000 09:49:52 PM,1800 Block of IRVING ST,SF,94122,B08,22,7424,1,1,2,false,,,,,1,MEDIC,1,8,4,Sunset/Parkside,"(37.763482287794, -122.477678638767)",001030122-M18
001030154,M36,00030662,Medical Incident,04/12/2000,04/12/2000,10:43:54 PM,04/12/2000 10:45:53 PM,04/12/2000 10:49:59 PM,04/12/2000 10:50:35 PM,04/12/2000 10:53:18 PM,04/12/2000 11:11:36 PM,04/12/2000 11:22:17 PM,Other,04/12/2000 11:42:43 PM,0 Block of SOUTH VAN NESS AVE,SF,94103,B02,36,5117,1,1,2,false,,,,,1,MEDIC,1,2,6,Mission,"(37.7741251002903, -122.418810211803)",001030154-M36
001040007,E12,00030697,Structure Fire,04/13/2000,04/12/2000,12:19:54 AM,04/13/2000 12:29:24 AM,04/13/2000 12:29:35 AM,04/13/2000 12:31:25 AM,04/13/2000 12:32:36 AM,,,,,Other,04/13/2000 12:33:18 AM,CLAYTON ST/PARNASSUS AV,SF,94117,B05,12,5151,3,3,3,true,,,,,1,ENGINE,1,5,5,Haight Ashbury,"(37.7651387353822, -122.44763462758)",001040007-E12
001040021,M14,00030711,Medical Incident,04/13/2000,04/13/2000,01:17:25 AM,04/13/2000 01:18:44 AM,04/13/2000 01:20:02 AM,04/13/2000 01:21:40 AM,04/13/2000 01:23:02 AM,04/13/2000 01:24:02 AM,04/13/2000 01:25:02 AM,04/13/2000 01:26:02 AM,04/13/2000 01:27:02 AM,04/13/2000 01:28:02 AM,04/13/2000 01:29:02 AM,04/13/2000 01:30:02 AM,04/13/2000 01:31:02 AM,04/13/2000 01:32:02 AM,04/13/2000 01:33:02 AM,04/13/2000 01:34:02 AM,04/13/2000 01:35:02 AM,04/13/2000 01:36:02 AM,04/13/2000 01:37:02 AM,04/13/2000 01:38:02 AM,04/13/2000 01:39:02 AM,04/13/2000 01:40:02 AM,04/13/2000 01:41:02 AM,04/13/2000 01:42:02 AM,04/13/2000 01:43:02 AM,04/13/2000 01:44:02 AM,04/13/2000 01:45:02 AM,04/13/2000 01:46:02 AM,04/13/2000 01:47:02 AM,04/13/2000 01:48:02 AM,04/13/2000 01:49:02 AM,04/13/2000 01:50:02 AM,04/13/2000 01:51:02 AM,04/13/2000 01:52:02 AM,04/13/2000 01:53:02 AM,04/13/2000 01:54:02 AM,04/13/2000 01:55:02 AM,04/13/2000 01:56:02 AM,04/13/2000 01:57:02 AM,04/13/2000 01:58:02 AM,04/13/2000 01:59:02 AM,04/13/2000 02:00:02 AM,04/13/2000 02:01:02 AM,04/13/2000 02:02:02 AM,04/13/2000 02:03:02 AM,04/13/2000 02:04:02 AM,04/13/2000 02:05:02 AM,04/13/2000 02:06:02 AM,04/13/2000 02:07:02 AM,04/13/2000 02:08:02 AM,04/13/2000 02:09:02 AM,04/13/2000 02:10:02 AM,04/13/2000 02:11:02 AM,04/13/2000 02:12:02 AM,04/13/2000 02:13:02 AM,04/13/2000 02:14:02 AM,04/13/2000 02:15:02 AM,04/13/2000 02:16:02 AM,04/13/2000 02:17:02 AM,04/13/2000 02:18:02 AM,04/13/2000 02:19:02 AM,04/13/2000 02:20:02 AM,04/13/2000 02:21:02 AM,04/13/2000 02:22:02 AM,04/13/2000 02:23:02 AM,04/13/2000 02:24:02 AM,04/13/2000 02:25:02 AM,04/13/2000 02:26:02 AM,04/13/2000 02:27:02 AM,04/13/2000 02:28:02 AM,04/13/2000 02:29:02 AM,04/13/2000 02:30:02 AM,04/13/2000 02:31:02 AM,04/13/2000 02:32:02 AM,04/13/2000 02:33:02 AM,04/13/2000 02:34:02 AM,04/13/2000 02:35:02 AM,04/13/2000 02:36:02 AM,04/13/2000 02:37:02 AM,04/13/2000 02:38:02 AM,04/13/2000 02:39:02 AM,04/13/2000 02:40:02 AM,04/13/2000 02:41:02 AM,04/13/2000 02:42:02 AM,04/13/2000 02:43:02 AM,04/13/2000 02:44:02 AM,04/13/2000 02:45:02 AM,04/13/2000 02:46:02 AM,04/13/2000 02:47:02 AM,04/13/2000 02:48:02 AM,04/13/2000 02:49:02 AM,04/13/2000 02:50:02 AM,04/13/2000 02:51:02 AM,04/13/2000 02:52:02 AM,04/13/2000 02:53:02 AM,04/13/2000 02:54:02 AM,04/13/2000 02:55:02 AM,04/13/2000 02:56:02 AM,04/13/2000 02:57:02 AM,04/13/2000 02:58:02 AM,04/13/2000 02:59:02 AM,04/13/2000 03:00:02 AM,04/13/2000 03:01:02 AM,04/13/2000 03:02:02 AM,04/13/2000 03:03:02 AM,04/13/2000 03:04:02 AM,04/13/2000 03:05:02 AM,04/13/2000 03:06:02 AM,04/13/2000 03:07:02 AM,04/13/2000 03:08:02 AM,04/13/2000 03:09:02 AM,04/13/2000 03:10:02 AM,04/13/2000 03:11:02 AM,04/13/2000 03:12:02 AM,04/13/2000 03:13:02 AM,04/13/2000 03:14:02 AM,04/13/2000 03:15:02 AM,04/13/2000 03:16:02 AM,04/13/2000 03:17:02 AM,04/13/2000 03:18:02 AM,04/13/2000 03:19:02 AM,04/13/2000 03:20:02 AM,04/13/2000 03:21:02 AM,04/13/2000 03:22:02 AM,04/13/2000 03:23:02 AM,04/13/2000 03:24:02 AM,04/13/2000 03:25:02 AM,04/13/2000 03:26:02 AM,04/13/2000 03:27:02 AM,04/13/2000 03:28:02 AM,04/13/2000 03:29:02 AM,04/13/2000 03:30:02 AM,04/13/2000 03:31:02 AM,04/13/2000 03:32:02 AM,04/13/2000 03:33:02 AM,04/13/2000 03:34:02 AM,04/13/2000 03:35:02 AM,04/13/2000 03:36:02 AM,04/13/2000 03:37:02 AM,04/13/2000 03:38:02 AM,04/13/2000 03:39:02 AM,04/13/2000 03:40:02 AM,04/13/2000 03:41:02 AM,04/13/2000 03:42:02 AM,04/13/2000 03:43:02 AM,04/13/2000 03:44:02 AM,04/13/2000 03:45:02 AM,04/13/2000 03:46:02 AM,04/13/2000 03:47:02 AM,04/13/2000 03:48:02 AM,04/13/2000 03:49:02 AM,04/13/2000 03:50:02 AM,04/13/2000 03:51:02 AM,04/13/2000 03:52:02 AM,04/13/2000 03:53:02 AM,04/13/2000 03:54:02 AM,04/13/2000 03:55:02 AM,04/13/2000 03:56:02 AM,04/13/2000 03:57:02 AM,04/13/2000 03:58:02 AM,04/13/2000 03:59:02 AM,04/13/2000 04:00:02 AM,04/13/2000 04:01:02 AM,04/13/2000 04:02:02 AM,04/13/2000 04:03:02 AM,04/13/2000 04:04:02 AM,04/13/2000 04:05:02 AM,04/13/2000 04:06:02 AM,04/13/2000 04:07:02 AM,04/13/2000 04:08:02 AM,04/13/2000 04:09:02 AM,04/13/2000 04:10:02 AM,04/13/2000 04:11:02 AM,04/13/2000 04:12:02 AM,04/13/2000 04:13:02 AM,04/13/2000 04:14:02 AM,04/13/2000 04:15:02 AM,04/13/2000 04:16:02 AM,04/13/2000 04:17:02 AM,04/13/2000 04:18:02 AM,04/13/2000 04:19:02 AM,04/13/2000 04:20:02 AM,04/13/2000 04:21:02 AM,04/13/2000 04:22:02 AM,04/13/2000 04:23:02 AM,04/13/2000 04:24:02 AM,04/13/2000 04:25:02 AM,04/13/2000 04:26:02 AM,04/13/2000 04:27:02 AM,04/13/2000 04:28:02 AM,04/13/2000 04:29:02 AM,04/13/2000 04:30:02 AM,04/13/2000 04:31:02 AM,04/13/2000 04:32:02 AM,04/13/2000 04:33:02 AM,04/13/2000 04:34:02 AM,04/13/2000 04:35:02 AM,04/13/2000 04:36:02 AM,04/13/2000 04:37:02 AM,04/13/2000 04:38:02 AM,04/13/2000 04:39:02 AM,04/13/2000 04:40:02 AM,04/13/2000 04:41:02 AM,04/13/2000 04:42:02 AM,04/13/2000 04:43:02 AM,04/13/2000 04:44:02 AM,04/13/2000 04:45:02 AM,04/13/2000 04:46:02 AM,04/13/2000 04:47:02 AM,04/13/2000 04:48:02 AM,04/13/2000 04:49:02 AM,04/13/2000 04:50:02 AM,04/13/2000 04:51:02 AM,04/13/2000 04:52:02 AM,04/13/2000 04:53:02 AM,04/13/2000 04:54:02 AM,04/13/2000 04:55:02 AM,04/13/2000 04:56:02 AM,04/13/2000 04:57:02 AM,04/13/2000 04:58:02 AM,04/13/2000 04:59:02 AM,04/13/2000 05:00:02 AM,04/13/2000 05:01:02 AM,04/13/2000 05:02:02 AM,04/13/2000 05:03:02 AM,04/13/2000 05:04:02 AM,04/13/2000 05:05:02 AM,04/13/2000 05:06:02 AM,04/13/2000 05:07:02 AM,04/13/2000 05:08:02 AM,04/13/2000 05:09:02 AM,04/13/2000 05:10:02 AM,04/13/2000 05:11:02 AM,04/13/2000 05:12:02 AM,04/13/2000 05:13:02 AM,04/13/2000 05:14:02 AM,04/13/2000 05:15:02 AM,04/13/2000 05:16:02 AM,04/13/2000 05:17:02 AM,04/13/2000 05:18:02 AM,04/13/2000 05:19:02 AM,04/13/2000 05:20:02 AM,04/13/2000 05:21:02 AM,04/13/2000 05:22:02 AM,04/13/2000 05:23:02 AM,04/13/2000 05:24:02 AM,04/13/2000 05:25:02 AM,04/13/2000 05:26:02 AM,04/13/2000 05:27:02 AM,04/13/2000 05:28:02 AM,04/13/2000 05:29:02 AM,04/13/2000 05:30:02 AM,04/13/2000 05:31:02 AM,04/13/2000 05:32:02 AM,04/13/2000 05:33:02 AM,04/13/2000 05:34:02 AM,04/13/2000 05:35:02 AM,04/13/2000 05:36:02 AM,04/13/2000 05:37:02 AM,04/13/2000 05:38:02 AM,04/13/2000 05:39:02 AM,04/13/2000 05:40:02 AM,04/13/2000 05:41:02 AM,04/13/2000 05:42:02 AM,04/13/2000 05:43:02 AM,04/13/2000 05:44:02 AM,04/13/2000 05:45:02 AM,04/13/2000 05:46:02 AM,04/13/2000 05:47:02 AM,04/13/2000 05:48:02 AM,04/13/2000 05:49:02 AM,04/13/2000 05:50:02 AM,04/13/2000 05:51:02 AM,04/13/2000 05:52:02 AM,04/13/2000 05:53:02 AM,04/13/2000 05:54:02 AM,04/13/2000 05:55:02 AM,04/13/2000 05:56:02 AM,04/13/2000 05:57:02 AM,04/13/2000 05:58:02 AM,04/13/2000 05:59:02 AM,04/13/2000 06:00:02 AM,04/13/2000 06:01:02 AM,04/13/2000 06:02:02 AM,04/13/2000 06:03:02 AM,04/13/2000 06:04:02 AM,04/13/2000 06:05:02 AM,04/13/2000 06:06:02 AM,04/13/2000 06:07:02 AM,04/13/2000 06:08:02 AM,04/13/2000 06:09:02 AM,04/13/2000 06:10:02 AM,04/13/2000 06:11:02 AM,04/13/2000 06:12:02 AM,04/13/2000 06:13:02 AM,04/13/2000 06:14:02 AM,04/13/2000 06:15:02 AM,04/13/2000 06:16:02 AM,04/13/2000 06:17:02 AM,04/13/2000 06:18:02 AM,04/13/2000 06:19:02 AM,04/13/2000 06:20:02 AM,04/13/2000 06:21:02 AM,04/13/2000 06:22:02 AM,04/13/2000 06:23:02 AM,04/13/2000 06:24:02 AM,04/13/2000 06:25:02 AM,04/13/2000 06:26:02 AM,04/13/2000 06:27:02 AM,04/13/2000 06:28:02 AM,04/13/2000 06:29:02 AM,04/13/2000 06:30:02 AM,04/13/2000 06:31:02 AM,04/13/2000 06:32:02 AM,04/13/2000 06:33:02 AM,04/13/2000 06:34:02 AM,04/13/2000 06:35:02 AM,04/13/2000 06:36:02 AM,04/13/2000 06:37:02 AM,04/13/2000 06:38:02 AM,04/13/2000 06:39:02 AM,04/13/2000 06:40:02 AM,04/13/2000 06:41:02 AM,04/13/2000 06:42:02 AM,04/13/2000 06:43:02 AM,04/13/2000 06:44:02 AM,04/13/2000 06:45:02 AM,04/13/2000 06:46:02 AM,04/13/2000 06:47:02 AM,04/13/2000 06:48:02 AM,04/13/2000 06:49:02 AM,04/13/2000 06:50:02 AM,04/13/2000 06:51:02 AM,04/13/2000 06:52:02 AM,04/13/2000 06:53:02 AM,04/13/2000 06:54:02 AM,04/13/2000 06:55:02 AM,04/13/2000 06:56:02 AM,04/13/2000 06:57:02 AM,04/13/2000 06:58:02 AM,04/13/2000 06:59:02 AM,04/13/2000 07:00:02 AM,04/13/2000 07:01:02 AM,04/13/2000 07:02:02 AM,04/13/2000 07:03:02 AM,04/13/2000 07:04:02 AM,04/13/2000 07:05:02 AM,04/13/2000 07:06:02 AM,04/13/2000 07:07:02 AM,04/13/2000 07:08:02 AM,04/13/2000 07:09:02 AM,04/13/2000 07:10:02 AM,04/13/2000 07:11:02 AM,04/13/2000 07:12:02 AM,04/13/2000 07:13:02 AM,04/13/2000 07:14:02 AM,04/13/2000 07:15:02 AM,04/13/2000 07:16:02 AM,04/13/2000 07:17:02 AM,04/13/2000 07:18:02 AM,04/13/2000 07:19:02 AM,04/13/2000 07:20:02 AM,04/13/2000 07:21:02 AM,04/13/2000 07:22:02 AM,04/13/2000 07:23:02 AM,04/13/2000 07:24:02 AM,04/13/2000 07:25:02 AM,04/13/2000 07:26:02 AM,04/13/2000 07:27:02 AM,04/13/2000 07:28:02 AM,04/13/2000 07:29:02 AM,04/13/2000 07:30:02 AM,04/13/2000 07:31:02 AM,04/13/2000 07:32:02 AM,04/13/2000 07:33:02 AM,04/13/2000 07:34:02 AM,04/13/2000 07:35:02 AM,04/13/2000 07:36:02 AM,04/13/2000 07:37:02 AM,04/13/2000 07:38:02 AM,04/13/2000 07:39:02 AM,04/13/2000 07:40:02 AM,04/13/2000 07:41:02 AM,04/13/2000 07:42:02 AM,04/13/2000 07:43:02 AM,04/13/2000 07:44:02 AM,04/13/2000 07:45:02 AM,04/13/2000 07:46:02 AM,04/13/2000 07:47:02 AM,04/13/2000 07:48:02 AM,04/13/2000 07:49:02 AM,04/13/2000 07:50:02 AM,04/13/2000 07:51:02 AM,04/13/2000 07:52:02 AM,04/13/2000 07:53:02 AM,04/13/2000 07:54:02 AM,04/13/2000 07:55:02 AM,04/13/2000 07:56:02 AM,04/13/2000 07:57:02 AM,04/13/2000 07:58:02 AM,04/13/2000 07:59:02 AM,04/13/2000 08:00:02 AM,04/13/2000 08:01:02 AM,04/13/2000 08:02:02 AM,04/13/2000 08:03:02 AM,04/13/2000 08:04:02 AM,04/13/2000 08:05:02 AM,04/13/2000 08:06:02 AM,04/13/2000 08:07:02 AM,04/13/2000 08:08:02 AM,04/13/2000 08:09:02 AM,04/13/2000 08:10:02 AM,04/13/2000 08:11:02 AM,04/13/2000 08:12:02 AM,04/13/2000 08:13:02 AM,04/13/2000 08:14:02 AM,04/13/2000 08:15:02 AM,04/13/2000 08:16:02 AM,04/13/2000 08:17:02 AM,04/13/2000 08:18:02 AM,04/13/2000 08:19:02 AM,04/13/2000 08:20:02 AM,04/13/2000 08:21:02 AM,04/13/2000 08:22:02 AM,04/13/2000 08:23:02 AM,04/13/2000 08:24:02 AM,04/13/2000 08:25:02 AM,04/13/2000 08:26:02 AM,04/13/2000 08:27:02 AM,04/13/2000 08:28:02 AM,04/13/2000 08:29:02 AM,04/13/2000 08:30:02 AM,04/13/2000 08:31:02 AM,04/13/2000 08:32:02 AM,04/13/2000 08:33:02 AM,04/13/2000 08:34:02 AM,04/13/2000 08:35:02 AM,04/13/2000 08:36:02 AM,04/13/2000 08:37:02 AM,04/13/2000 08:38:02 AM,04/13/2000 08:39:02 AM,04/13/2000 08:40:02 AM,04/13/2000 08:41:02 AM,04/13/2000 08:42:02 AM,04/13/2000 08:43:02 AM,04/13/2000 08:44:02 AM,04/13/2000 08:45:02 AM,04/13/2000 08:46:02 AM,04/13/2000 08:47:02 AM,04/13/2000 08:48:02 AM,04/13/2000 08:49:02 AM,04/13/2000 08:50:02 AM,04/13/2000 08:51:02 AM,04/13/2000 08:52:02 AM,04/13/2000 08:53:02 AM,04/13/2000 08:54:02 AM,04/13/2000 08:55:02 AM,04/13/2000 08:56:02 AM,04/13/2000 08:57:02 AM,04/13/2000 08:58:02 AM,04/13/2000 08:59:02 AM,04/13/2000 09:00:02 AM,04/13/2000 09:01:02 AM,04/13/2000 09:02:02 AM,04/13/2000 09:03:02 AM,04/13/2000 09:04:02 AM,04/13/2000 09:05:02 AM,04/13/2000 09:06:02 AM,04/13/2000 09:07:02 AM,04/13/2000 09:08:02 AM,04/13/2000 09:09:02 AM,04/13/2000 09:10:02 AM,04/13/2000 09:11:02 AM,04/13/2000 09:12:02 AM,04/13/2000 09:13:02 AM,04/13/2000 09:14:02 AM,04/13/2000 09:15:02 AM,04/13/2000 09:16:02 AM,04/13/2000 09:17:02 AM,04/13/2000 09:18:02 AM,04/13/2000 09:19:02 AM,04/13/2000 09:20:02 AM,04/13/2000 09:21:02 AM,04/13/2000 09:22:02 AM,04/13/2000 09:23:02 AM,04/13/2000 09:24:02 AM,04/13/2000 09:25:02 AM,04/13/2000 09:26:02 AM,04/13/2000 09:27:02 AM,04/13/2000 09:28:02 AM,04/13/2000 09:29:02 AM,04/13/2000 09:30:02 AM,04/13/2000 09:31:02 AM,04/13/2000 09:32:02 AM,04/13/2000 09:33:02 AM,04/13/2000 09:34:02 AM,04/13/2000 09:35:02 AM,04/13/2000 09:36:02 AM,04/13/2000 09:37:02 AM,04/13/2000 09:38:02 AM,04/13/2000 09:39:02 AM,04/13/2000 09:40:02 AM,04/13/2000 09:41:02 AM,04/13/2000 09:42:02 AM,04/13/2000 09:43:02 AM,04/13/2000 09:44:02 AM,04/13/2000 09:45:02 AM,04/13/2000 09:46:02 AM,04/13/2000 09:47:02 AM,04/13/2000 09:48:02 AM



databricks

1.4-SQL-Notebook SQL ☆

File Edit View Run Help Last edit was 10 minutes ago New cell UI: OFF

Run all My Cluster Share Publish

Take a look at a sample of the data.

Cmd 15

```
1 SELECT * FROM fireCalls LIMIT 10
```

(1) Spark Jobs

	Call Number	Unit ID	Incident Number	Call Type	Call Date	Watch Date	Received DTm	Entry DTm	Dispatch DTm
1	1030118	E08	30625	Medical Incident	2000-04-12	2000-04-12	04/12/2000 09:27:45 PM	04/12/2000 09:28:58 PM	04/12/2000 09:29:21
2	1030122	M18	30630	Medical Incident	2000-04-12	2000-04-12	04/12/2000 09:31:55 PM	04/12/2000 09:33:48 PM	04/12/2000 09:34:10
3	1030154	M36	30662	Medical Incident	2000-04-12	2000-04-12	04/12/2000 10:43:54 PM	04/12/2000 10:45:53 PM	04/12/2000 10:49:59
4	1040007	E12	30697	Structure Fire	2000-04-13	2000-04-12	04/13/2000 12:19:54 AM	04/13/2000 12:29:24 AM	04/13/2000 12:29:35
5	1040021	M14	30711	Medical Incident	2000-04-13	2000-04-12	04/13/2000 01:17:25 AM	04/13/2000 01:18:44 AM	04/13/2000 01:20:02
6	1040061	M43	30749	Medical Incident	2000-04-13	2000-04-12	04/13/2000 07:51:29 AM	04/13/2000 07:55:35 AM	04/13/2000 07:55:54

10 rows | 2.23 seconds runtime Refreshed 1 minute ago

Command took 2.23 seconds -- by victorpointud1112@gmail.com at 16/03/2024, 17:51:05 on My Cluster

Cmd 16

Which neighborhoods have the most fire calls?

Cmd 17

```
1 SELECT 'Neighborhoods - Analysis Boundaries' as neighborhood,
2 COUNT('Neighborhoods - Analysis Boundaries') as count
3 FROM FireCalls
4 GROUP BY 'Neighborhoods - Analysis Boundaries'
5 ORDER BY count DESC
```

(2) Spark Jobs

databricks

1.4-SQL-Notebook SQL ☆

File Edit View Run Help Last edit was 10 minutes ago New cell UI: OFF

Run all My Cluster Share Publish

	neighborhood	count
1	Tenderloin	31564
2	South of Market	23212
3	Mission	21829
4	Financial District/South Beach	16384
5	Bayview Hunters Point	13057
6	Sunset/Parkside	9456

42 rows | 8.86 seconds runtime Refreshed 1 minute ago

Command took 8.86 seconds -- by victorpointud1112@gmail.com at 16/03/2024, 17:51:05 on My Cluster

Cmd 18

Visualizing your Data


We can use the built-in Databricks visualization to see which neighborhoods have the most fire calls.

Cmd 19

```
1 SELECT 'Neighborhoods - Analysis Boundaries' as neighborhood,
2 COUNT('Neighborhoods - Analysis Boundaries') as count
3 FROM fireCalls
4 GROUP BY 'Neighborhoods - Analysis Boundaries'
5 ORDER BY count DESC
6
```

(2) Spark Jobs

	neighborhood	count
--	--------------	-------



The screenshot shows a Databricks SQL Notebook interface. At the top, it says "1.4-SQL-Notebook" and "SQL". Below the notebook title, there's a table with 2 columns: "neighborhood" and "count". The table has 6 rows of data. Below the table, it says "42 rows | 4.28 seconds runtime" and "Refreshed 1 minute ago". At the bottom, there's a command bar with the text "Command took 4.28 seconds — by victorpointud1112@gmail.com at 16/03/2024, 17:51:05 on My Cluster".

	neighborhood	count
1	Tenderloin	31564
2	South of Market	23212
3	Mission	21829
4	Financial District/South Beach	16384
5	Bayview Hunters Point	13057
6	Sunset/Parkside	9456

6. Usarlo como guía para la parte 2.

Parte II

Kaggle es una plataforma web que reúne la comunidad Data Science más grande del mundo, con más de 536 mil miembros activos en 194 países, recibe más de 150 mil publicaciones por mes, que brindan todas las herramientas y recursos más importantes para progresar al máximo en data science. Hay más de 50 mil conjuntos de datos públicos y 400 mil notas públicas disponibles para todo el mundo.

1. Crea una cuenta en <https://www.kaggle.com/>
2. Descarga el archivo `Athletes_summer_games.csv` desde https://www.kaggle.com/datasets/nitishsharma01/olympics-124-years-datasettil-2020?select=Athletes_summer_games.csv

En spark

3. Crear la tabla ASG con el archivo, con la primera fila como encabezado e infiriendo el esquema.
4. Crear un notebook desde la pantalla de crear tabla y cambiarle el nombre a TareaSparksSQL<nombres integrantes>

5. Cambiar el lenguaje de cuaderno a SQL

6. Realizar las siguientes consultas (7 pts)

- Nombre, sexo, edad y equipo de los atletas del país “NOC” que usted escoja que participaron en juegos del 2016
- El total de jugadores del equipo español que participaron en algún juego ordenados de mayor a menor
- el total de jugadores que participaron en juegos donde participó USA en años mayores a 2012 ordenados de mayor a menor
- Los 10 primeros países que han ganado más medallas de oro.
- Cantidad de deportes celebrados en la ciudad de Barcelona, agrupados por año y por equipo.
- Los 10 equipos que han tenido más participación femenina

7. Escoge una consulta, y expanda Spark Jobs (3 pts)

Cmd 1

```

1 SELECT
2   Name,
3   Sex,
4   Age
5 FROM
6   default.athletes_summer_games_3_csv
7 WHERE
8   NOC = "ROU"
9   AND Year = 2016;

```

▼ (3) Spark Jobs

- ▼ Job 20 View (Stages: 1/1)
Stage 20 1/1 succeeded View
- ▼ Job 21 View (Stages: 1/1)
Stage 21 4/4 succeeded View
- ▼ Job 22 View (Stages: 1/1)
Stage 22 3/3 succeeded View

Table +

	Name	Sex	Age
1	Andreea Aanei	F	22
2	Constantin Adam	M	20
3	Vlad-Drago Aicobose	M	22
4	Alin Alexuc-Ciurariu	M	26
5	Andreea Arsine	F	27
6	Florina Maria Brsan-Chintoan	F	30
7	Irina Camelia Reau	F	25

121 rows | 7.61 seconds runtime

Command took 7.61 seconds -- by bernardoh.lander1@gmail.com at 3/28/2024, 9:48:24 PM on My Cluster 2 (clone)

Details for Stage 20 (Attempt 0)

Resource Profile Id: 0
Total Time Across All Tasks: 1 s
Locality Level Summary: Process local: 1
Input Size / Records: 0.0 B / 22
Associated Job Ids: 20

- ▶ DAG Visualization
- ▶ Show Additional Metrics
- ▶ Event Timeline

Summary Metrics for 1 Completed Tasks

Metric	Min	25th percentile	Median	75th percentile	Max
Duration	1 s	1 s	1 s	1 s	1 s
GC Time	0.0 ms	0.0 ms	0.0 ms	0.0 ms	0.0 ms
Input Size / Records	0.0 B / 22	0.0 B / 22	0.0 B / 22	0.0 B / 22	0.0 B / 22

▶ Aggregated Metrics by Executor

Tasks (1)

Show 20 entries

Index #	Task ID	Attempt	Status	Locality level	Executor ID	Host	Logs	Launch Time	Duration	GC Time	Shuffle Read Fetch Wait Time	Shuffle Remote Reads	Input Size / Records	Shuffle Write Time	Errors
0	42	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:27	1 s		0.0 ms	0.0 B	0.0 B / 22		

Showing 1 to 1 of 1 entries

Previous Next

Jobs Stages Storage Environment Executors SQL / DataFrame JDBC/ODBC Server Structured Streaming Connect

Details for Stage 21 (Attempt 0)

Resource Profile Id: 0
Total Time Across All Tasks: 8 s
Locality Level Summary: Process local: 4
Input Size / Records: 0.0 B / 78
Associated Job Ids: 21

- ▶ DAG Visualization
- ▶ Show Additional Metrics
- ▶ Event Timeline

Summary Metrics for 4 Completed Tasks

Metric	Min	25th percentile	Median	75th percentile	Max
Duration	2 s	2 s	2 s	2 s	2 s
GC Time	0.0 ms	0.0 ms	0.0 ms	0.0 ms	0.0 ms
Input Size / Records	0.0 B / 7	0.0 B / 11	0.0 B / 24	0.0 B / 36	0.0 B / 36

▶ Aggregated Metrics by Executor

Tasks (4)

Show 20 entries

Index #	Task ID	Attempt	Status	Locality level	Executor ID	Host	Logs	Launch Time	Duration	GC Time	Shuffle Read Fetch Wait Time	Shuffle Remote Reads	Input Size / Records	Shuffle Write Time	Errors
1	43	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:29	2 s		0.0 ms	0.0 B	0.0 B / 24		
2	44	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:29	2 s		0.0 ms	0.0 B	0.0 B / 7		
3	45	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:29	2 s		0.0 ms	0.0 B	0.0 B / 11		
4	46	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:29	2 s		0.0 ms	0.0 B	0.0 B / 36		

Showing 1 to 4 of 4 entries

Previous Next

Jobs Stages Storage Environment Executors SQL / DataFrame JDBC/ODBC Server Structured Streaming Connect

Details for Stage 22 (Attempt 0)

Resource Profile Id: 0
Total Time Across All Tasks: 2 s
Locality Level Summary: Process local: 3
Input Size / Records: 0.0 B / 21
Associated Job Ids: 22

- ▶ DAG Visualization
- ▶ Show Additional Metrics
- ▶ Event Timeline

Summary Metrics for 3 Completed Tasks

Metric	Min	25th percentile	Median	75th percentile	Max
Duration	0.3 s	0.3 s	0.9 s	0.9 s	0.9 s
GC Time	0.0 ms	0.0 ms	0.0 ms	0.0 ms	0.0 ms
Input Size / Records	0.0 B / 0	0.0 B / 0	0.0 B / 5	0.0 B / 16	0.0 B / 16

▶ Aggregated Metrics by Executor

Tasks (3)

Show 20 entries

Index #	Task ID	Attempt	Status	Locality level	Executor ID	Host	Logs	Launch Time	Duration	GC Time	Shuffle Read Fetch Wait Time	Shuffle Remote Reads	Input Size / Records	Shuffle Write Time	Errors
5	47	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:31	0.9 s		0.0 ms	0.0 B	0.0 B / 16		
6	48	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:31	0.9 s		0.0 ms	0.0 B	0.0 B / 5		
7	49	0	SUCCESS	PROCESS_LOCAL	driver	ip-10-172-168-247.us-west-2.compute.internal		2024-03-20 21:48:31	0.3 s		0.0 ms	0.0 B			

Showing 1 to 3 of 3 entries

Previous Next

a. De clic a cada View y diga cuantas etapas tiene el DAG (haga un print)

b. De clic al DAG para mayores detalles



Details for Job 20

Status: SUCCEEDED

Submitted: 2024/03/21 01:48:27

Duration: 1 s


Associated SQL Query: 60

Job Group: 5368604649243222948_8295093646489730015_6116e60da0fc46c592c484ca19a5fa28

Completed Stages: 1

► Event Timeline

▼ DAG Visualization



Details for Job 21

Status: SUCCEEDED

Submitted: 2024/03/21 01:48:29

Duration: 2 s


Associated SQL Query: 60

Job Group: 5368604649243222948_8295093646489730015_6116e60da0fc46c592c484ca19a5fa28

Completed Stages: 1

► Event Timeline

▼ DAG Visualization



Details for Stage 22 (Attempt 0)

Resource Profile Id: 0


Total Time Across All Tasks: 2 s

Locality Level Summary: Process local: 3

Input Size / Records: 0.0 B / 21

Associated Job Ids: 22

▼ DAG Visualization



c. Identifique una transformación angosta y una ancha, explique

Transformación angosta: Implica convertir un conjunto de datos de modo que tenga más filas y menos columnas. Este enfoque aumenta la cantidad de filas, ya que los valores que podrían haber ocupado varias columnas en un formato ancho se distribuyen a través de múltiples filas, con posiblemente una columna que indica el tipo de dato y otra el valor. Las transformaciones angostas son útiles para normalizar datos y para sistemas que manejan mejor un mayor número de filas que de columnas.

Ejemplo: WHERE Team = 'United States' AND Year > 2012

Transformación ancha: Implica convertir un conjunto de datos para que tenga menos filas y más columnas. Este enfoque disminuye la cantidad de filas al distribuir los datos a través de múltiples columnas, lo que puede facilitar ciertos tipos de análisis y visualización de datos, ya que cada variable se encuentra en su propia columna. Un formato ancho puede ser más intuitivo para la visualización y análisis de datos, especialmente cuando se trabajan con herramientas de análisis que esperan datos en este formato.

Ejemplo: GROUP BY COUNT(Distinct Name) AS TotalPlayers

d. identifique una acción, explique

COUNT(Distinct Name) AS TotalPlayers

En resumen, COUNT(Distinct Name) AS TotalPlayers cuenta el número total de nombres únicos en la columna Name de una tabla y presenta ese recuento como TotalPlayers. Esta operación es útil, por ejemplo, en una base de datos de un juego o una competición deportiva, para determinar el número total de jugadores diferentes que han participado, ignorando duplicados para asegurarse de que cada jugador se cuenta solo una vez.

8. De formato a su cuaderno con la descripción de cada consulta y su nombre, luego publique el cuaderno y copie el enlace en la entrega.

- <https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93ea-aa8714f173bcfc/4586701092919010/1247724403113861/5578417581696535/latest.html>

Parte III

Contestar las siguientes preguntas (8 ptos)

1. Explique que es un RDD y qué hace que sea resiliente.

- Los RDD o Resilient Distributed Datasets, son estructuras de datos paralelas, inmutables y tolerantes a fallas que permiten persistencia explícita de los resultados intermedios en la memoria lo que facilita la recuperación en caso de un fallo, además permiten un control fino sobre la partición de datos optimizando el rendimiento.
- La resiliencia de los RDD se debe a su inmutabilidad y a su linaje de datos. La inmutabilidad hace referencia a que una vez creado no puede ser modificado y esta característica es esencial para la resiliencia ya que esto garantiza que los datos originales permanezcan intactos, y a su linaje de datos, que probablemente es la característica más importante referente a la resiliencia, es esencialmente como un historial completo de todas las transformaciones responsables por crear nuevos RDDs, con esto spark usa el linaje para recuperar RDDs perdidos o dañados para reconstruirlos a partir de los datos originales a través de la información registrada en el linaje, eliminando la necesidad de replicar datos y logrando una mayor tolerancia a fallos.

2. Cual es la diferencia entre una transformación estrecha y una amplia, cual es más rápida y por qué .

- La diferencia principal también es responsable por la diferencia de rendimiento entre cada tipo de transformación, que es la necesidad de un shuffle, el shuffle es una reorganización de los datos entre particiones a través de los nodos del clúster, se requiere cuando la operación no se puede realizar con una única partición.
- Las transformaciones estrechas no requieren un shuffle, las amplias si, y un shuffle puede ser intensivo en cuanto a términos de recursos, por lo que las transformaciones estrechas son generalmente más rápidas que las amplias.
- Importante también mencionar que una diferencia crucial es que la partición de salida de las transformaciones estrechas dependen de una sola partición de entrada, mientras que las particiones de salida de las amplias dependen de varias particiones de entrada.

3. Explique el proceso de optimización de una consulta en SparkSQL

Este proceso entero se realiza a través de su motor catalyst, el mismo aplica una serie de reglas y estrategias de optimización a un plan de ejecución para producir un plan de ejecución físico optimizado.

1. **Interpretación de la consulta:** Se construye un árbol de análisis abstracto (AST) que representa toda la lógica de la consulta, durante este proceso Spark también verifica la existencia de las tablas y columnas. (Se genera un plan lógico no resuelto)
2. **Resolución de la lógica:** El plan lógico no resuelto se convierte en uno resuelto a través de la aplicación de reglas lógicas para simplificar la consulta, como la eliminación de subconsultas redundantes, se optimizan los joins por mencionar algunos ejemplos, este plan lógico resuelto sigue siendo una representación de alto nivel de la consulta escrita en un lenguaje declarativo.
3. **Optimización de la lógica:** El optimizador de Catalyst se encarga de aplicar un conjunto de reglas de optimización al plan lógico resuelto para mejorar la eficiencia, esto incluye reordenar joins, eliminar proyecciones o filtros innecesarios, combinar operaciones, etc. El resultado de este paso, es un plan lógico optimizado que sigue siendo equivalente a la consulta original y está listo para comenzar con la planificación física.
4. **Planificación física:** Basándose en el plan lógico ya optimizado, Spark genera múltiples planes físicos posibles que especifican cómo se podría ejecutar la consulta en el cluster, cada plan físico es una estrategia diferente.
5. **Selección del plan:** Entre los distintos planes físicos generados, Spark selecciona el más eficiente basándose en un modelo de costos. Este modelo estima el costo de cada uno de los planes basándose en varios factores, como la cantidad de datos a procesar, la complejidad de las operaciones a realizar y la distribución de los datos. Una vez ya se haya conseguido el plan con el menor costo, se selecciona para la ejecución.
6. **Generación del código:** Por último, ya seleccionado el plan físico, spark genera código bytecode Java para la JVM(Java Virtual Machine). Esto optimiza aún más la ejecución ya que se compilan partes críticas de la consultas en código nativo que se ejecuta en el JVM, reduciendo el tiempo de ejecución.

4. Cuales son las funciones del Grafo Acíclico Dirigido en Spark.

El DAG desempeña varias funciones claves que son esenciales para el procesamiento de un gran conjunto de datos en un entorno distribuido:

- Es responsable por el uso inteligente de la memoria caché, evitando tener que escribir constantemente en disco, lo que lo hace más rápido.
- Toda tarea en Spark crea un DAG de etapas de trabajo para que se ejecuten en un cluster, también planifica de manera óptima la secuencia de operaciones necesarias para ejecutar una consulta. (transformaciones y acciones)
- Optimización de procesos: El DAG optimiza el procesamiento de datos, por ejemplo puede reducir la cantidad de datos que pasen por un shuffle, mediante la optimización de la localización de los datos.
- Juega un papel clave en la tolerancia a fallos, en caso de que falle una tarea, Spark puede reutilizar el DAG para volver a computar sólo las partes afectadas del dataset en vez de computar todo de nuevo.
- Ejecución eficiente: Al usar el DAG para planificar y ejecutar tareas, Spark puede aprovecharse de las optimizaciones como del Lazy Evaluation para optimizar el plan de ejecución global combinando las operaciones para minimizar el trabajo innecesario.
- Visualización y depuración: El DAG proporciona una representación visual de todas las operaciones de transformación y acción en Spark, lo que generalmente es muy útil para la depuración y optimización de rendimiento.

5. Explique el modelo de procesamiento de datos de la pila unificada de Spark .

El modelo de procesamiento de datos de la pila unificada de spark proporciona una abstracción para el procesamiento de datos llamada RDD, sin duda hace más simple el desarrollo de aplicaciones. Está compuesto por 5 componentes clave que permite a los usuarios realizar una amplia variedad de tareas de análisis de datos y procesamiento de datos en un mismo sistema.

- **Apache Spark Core:** El corazón de Apache Spark es Spark Core, que proporciona capacidades fundamentales de procesamiento de datos, incluyendo la programación de trabajos, gestión de memoria, tolerancia a fallos, interacción con sistemas de almacenamiento, y más. Implementa el concepto de RDD (Resilient Distributed Dataset). Es responsable de coordinar y distribuir las tareas, manejar las fallas y de trasladar eficientemente los datos entre máquinas.

- **Spark SQL:** Es un módulo de spark que permite el procesamiento de datos estructurados y semi-estructurados. Tiene una interfaz similar a SQL para realizar consultas facilitando la integración de herramientas de BI y de análisis de datos. Utiliza Data Frames y Data Sets para permitir operaciones de alto nivel y optimización de consultas.
- **Spark Streaming:** Fue construido sobre el motor SparkSQL y las API basadas en Data Frame, es capaz de procesar datos de transmisión en tiempo real (gracias a que spark streaming extendió al modelo de spark core) desde varias fuentes de datos. Permite realizar tareas como análisis en tiempo real, filtrado y agregaciones con mínima latencia.
- **MLlib:** Es una biblioteca de Machine Learning de spark, proporciona una amplia variedad de algoritmos y herramientas de machine learning comunes, como clasificación, regresión, clustering, filtering, entre otras, así como infraestructuras para construir pipelines de ML personalizables. Esto te permite construir modelos de ML dentro del mismo framework de spark.
- **GraphX:** Este componente es responsable del procesamiento de grafos en spark, permite a los usuarios crear, transformar y trabajar con grafos. Incluye una colección de algoritmos comunes de procesamiento de grafos como Pagerank. Esto facilita el análisis de los grafos a gran escala, permitiendo a los usuarios realizar cálculos complejos sobre ellos de manera eficiente y distribuida. Esto se utiliza en una gran variedad de aplicaciones, incluyendo análisis de redes sociales, detección de fraudes en transacciones, sistemas de recomendación entre otros.